

文章编号: 1001-0920(2010) 03-0445-04

基于 V_{\min} -EKF 的动力锂电池组 SOC 估计

刘新天, 刘兴涛, 何 耀, 陈宗海
(中国科学技术大学 自动化系, 合肥 230027)

摘 要: 动力电池组的荷电状态(SOC)是电动汽车能量控制的重要参数. 针对串联锂电池组的 SOC 估计问题, 建立电池组的 V_{\min} 状态空间模型, 电池组内单体电池负载电压的最小值 V_{\min} 和电池组的 SOC 分别作为模型的观测变量和状态变量. 应用扩展卡尔曼滤波算法, 实现对 SOC 的动态估计. 对模拟电动汽车的实际工况进行电池组放电实验, 结果表明, 该方法能实时准确地估计电池组 SOC.

关键词: 动力锂电池组; 荷电状态; V_{\min} 模型; 扩展卡尔曼滤波

中图分类号: TM912

文献标识码: A

Based- V_{\min} -EKF SOC estimation for power Li-ion battery pack

LIU Xin-tian, LIU Xing-tao, HE Yao, CHEN Zong-hai

(Department of Automation, University of Science and Technology of China, Hefei 230027, China. Correspondent: CHEN Zong-hai, E-mail: chenzh@ustc.edu.cn)

Abstract: State-of-charge (SOC) of power battery pack is an important parameter for electrical vehicle. Aiming at SOC estimation for Li-ion battery pack of multi cells in series, a V_{\min} state space model of battery pack is proposed. The minimal cell load voltage of the battery pack is the model observation variable, and SOC is the model state variable. By applying extended Kalman filter, dynamic state estimation of SOC is realized. The experiment is made to simulate the behaviors of battery pack in the actual work conditon of electrical vehicle. The result shows that the accurate and real-time estimation of SOC can be obtained by using this approach.

Key words: Power Li-ion battery pack; State-of-charge; V_{\min} model; Extened Kalman filter

1 引言

电动汽车(EV)是未来汽车的一大发展方向. 动力锂电池组是电动汽车动力源, 其荷电状态(SOC)直接反应了电池组剩余容量的多少, 由此可预测 EV 的行驶里程, 同时也为电池组的使用和维护提供重要依据^[1].

由于电动汽车电池组在使用过程中表现出高度非线性, 使准确估计 SOC 具有很大难度^[2], 精确实时的锂电池组 SOC 估计也成为 EV 研究的一大重要挑战. 目前常用的 SOC 估计方法是通过测量电池组的外特性(电流、电压、内阻等)来对 SOC 进行估计. 安时积分法通过电池组负载电流的动态积分来估计 SOC, 算法简单, 实用性强. 但是由于它是一种开环预测, 会因为电流误差的累积导致精度越来越差^[3,4]. 神经网络法适合在线估计, 但需要相似电池组的大量训练数据^[5,6]. 扩展 Kalman 滤波(EKF)法

通过建立电池组的非线性状态空间模型, 结合递推算法实现对模型状态变量 SOC 的最小方差估计, 并能给出估计误差范围. 此外, EKF 方法对 SOC 的初始误差有较强的修正作用, 特别适用于电流变化较快的电动汽车动力电池组^[1], 其关键在于电池组状态空间模型的建立. Plett^[7]在简化电化学模型的基础上提出组合模型. Bhangu 等^[8]提出 RC 电路等效模型. Lee 等^[9]在 RC 电路模型的基础上提出了改进 OCV-SOC 关系模型. 上述模型均为单体电池的模型, 对于几十节甚至上百节单体电池串联的动力电池组, 单体电池间容量差异会随电池组循环次数增加而逐渐增大, 进而导致各单体电池的 SOC 不尽相同. 直接应用单体电池的模型来估计电池组 SOC 需对每个电池建立模型, 这对电动汽车电池组而言很难实现.

本文提出基于 V_{\min} 模型的 EKF 方法, 检测串联

收稿日期: 2009-04-10; 修回日期: 2009-08-05.

基金项目: 国家 863 计划项目(2009AA11A113); 江苏省工业装备数字制造及控制技术重点实验室开放研究基金项目(DM2008001); 合肥市重大科技计划项目(合科 20081033).

作者简介: 刘新天(1981—), 男, 安徽桐城人, 博士生, 从事电动汽车、电源管理的研究; 陈宗海(1963—), 男, 安徽桐城人, 教授, 博士生导师, 从事复杂系统建模、仿真与控制等研究.

动力锂电池组每个单体电池的负载电压值,取其最小值为 V_{\min} , V_{\min} 的变化直接体现了电池组 SOC 的变化. 以 V_{\min} 为观测变量, 电池组 SOC 为状态变量建立电池组非线性状态空间模型. 通过一阶 Taylor 展开将该状态空间模型线性化, 进而应用 Kalman 滤波法实现对电池组 SOC 的递归估计.

2 锂电池组 V_{\min} 模型

N 节电池串联的电池组内单体电池的负载电压计算如下:

$$V(n) = V_{oc}(n) - iR(n).$$
 (1)

其中: $V(n)$ 为电池组第 n 节电池 B_n 的负载电压, $V_{oc}(n)$ 为 B_n 的开路电压, i 表示电池组的放电电流, $R(n)$ 为 B_n 的内阻. 对于串联电池组, 所有单体电池放电电流 i 相同, 内阻 $R(n)$ 相差很小. 令单体电池的内阻近似为 R , 有

$$\begin{aligned} V_{\min} &= \min(V(1), V(2), \dots, V(N)) = \\ &= \min(V_{oc}(1), V_{oc}(2), \dots, V_{oc}(N)) - iR = \\ &= \min(h(SOC_1), h(SOC_2), \dots, h(SOC_N)) - iR = \\ &= h(\min(SOC_1, SOC_2, \dots, SOC_N)) - iR, \end{aligned}$$
 (2)

其中 SOC_n 是 B_n 的荷电状态. 对于单体电池, 开路电压 V_{oc} 与电池 SOC 存在单调递增的函数关系 $h^{[9]}$. 从而 V_{\min} 与电池组中单体电池 SOC 的最小值存在单调对应关系. 由于串联电池组的木桶效应, 多电池串联电池组的放电容量由容量最低的单体电池所决定, 即电池组的 SOC 等同于组内单体电池 SOC 的最小值. 综上所述, V_{\min} 的变化体现了电池组的 SOC 变化.

动力锂电池组的 V_{\min} 模型是以 V_{\min} 为观测变量, SOC 为状态变量所建立的电池组的状态空间模型, V_{\min} 模型的观测值能很好地反应状态变量——电池组 SOC 的变化.

2.1 SOC 状态方程

SOC 状态方程为

$$SOC(t) = SOC(0) - \frac{\int_0^t \eta_c i(t) dt}{C_N}.$$
 (3)

其中: $SOC(t)$ 是 t 时刻的瞬时 SOC 值; $SOC(0)$ 是初始 SOC 值; C_N 是电池组的额定容量; $i(t)$ 是 t 时刻的瞬时电流值; η_c 是库伦效率, 通常在放电情况下 $\eta_c = 1$.

SOC 的状态方程是基于安时积分法的原理, 根据放电电流积分值, 得到一个剩余容量占总容量的百分比, 即 SOC 值.

2.2 V_{\min} 模型观测方程

电池组的观测方程描述了 SOC、电流、内阻等因素与 V_{\min} 的数学关系, 借鉴单体电池组合模型^[7]

建立电池组非线性状态空间模型的观测方程如下:

$$\begin{aligned} V_{\min}(t) &= V_0 - Ri(t) - K_0/SOC(t) - \\ &= K_1SOC(t) + K_2\ln(SOC(t)) + \\ &= K_3\ln(1 - SOC(t)). \end{aligned}$$
 (4)

其中: V_0 是单体电池充满电后的空载电压; R 是单体电池的内阻; $i(t)$ 是 t 时刻的瞬时电流值; $SOC(t)$ 是 t 时刻的瞬时荷电状态; K_0, K_1, K_2, K_3 是模型的系数.

3 基于 V_{\min} 模型的 EKF 估计

Kalman 滤波算法是由 Kalman 提出的一种递推滤波方法, 用于解决线性系统状态变量的最优估计问题. 对于非线性系统的状态估计, 首先建立系统的离散状态空间模型, 用一阶 Taylor 近似展开将该状态空间模型线性化; 进而应用 Kalman 算法实现对状态变量的最小方差估计, 称为扩展 Kalman 滤波法(EKF)^[10].

将 EKF 应用到电池组的 SOC 估计, 首先构建动力锂电池组的离散状态空间模型, 模型由状态变量的递推方程和观测方程组成. SOC 是状态变量 x_k 的唯一分量, 模型的观测变量 y_k 为 V_{\min} . 将式(3)和(4)离散化有

$$\begin{aligned} x_{k+1} &= x_0 - \sum_{m=0}^k \frac{\eta_c \Delta t}{C_N} i_m = \\ &= (x_0 - \sum_{m=0}^{k-1} \frac{\eta_c \Delta t}{C_N} i_m) - \frac{\eta_c \Delta t}{C_N} i_k = \\ &= x_k - \frac{\eta_c \Delta t}{C_N} i_k, \end{aligned}$$
 (5)

$$\begin{aligned} y_k &= V_0 - Ri_k - K_0/x_k - K_1x_k + \\ &= K_2\ln(x_k) + K_3\ln(1 - x_k) + v_k, \end{aligned}$$
 (6)

其中 Δt 为采样周期.

综合式(5)和(6), 得到电池组的离散状态空间模型为

$$\begin{aligned} x_{k+1} &= f(x_k, i_k) + w_k = \\ &= x_k - \frac{\eta_c \Delta t}{C_N} i_k + w_k, \\ y_k &= g(x_k, i_k) + v_k = \\ &= V_0 - Ri_k - K_0/x_k - K_1x_k + \\ &= K_2\ln(x_k) + K_3\ln(1 - x_k) + v_k, \end{aligned}$$
 (7)

其中 w_k 和 v_k 分别为系统噪声和观测噪声, 两者均为 Gauss 白噪声, 协方差分别为 Q_w 和 Q_v .

V_{\min} -EKF 方法的递推过程如下: 定义

$$\begin{aligned} A_{k-1} &= \frac{\partial f(x_{k-1}, i_{k-1})}{\partial x_{k-1}} \Big|_{x_{k-1} = \hat{x}_{k-1}} = 1, \\ C_k &= \frac{\partial g(x_k, i_k)}{\partial x_k} \Big|_{x_k = \hat{x}_k} = \\ &= K_0/(\hat{x}_k)^2 - K_1 + K_2/\hat{x}_k - K_3/(1 - \hat{x}_k). \end{aligned}$$

初始化过程如下: 令 $k = 0$, 可得

$$\hat{x}_0 = E[x_0],$$
$$P_0 = E[(x_0 - \hat{x}_0)(x_0 - \hat{x}_0)^T].$$

$k = 1, 2, \dots$ 的递推方程如下: 状态时间更新方程为 $\hat{x}_k^- = f(\hat{x}_{k-1}, i_{k-1})$; 误差协方差时间更新方程为 $P_k^- = A_k P_{k-1} A_k^T + Q_w$; 计算 Kalman 增益为 $K_k = P_k^- C_k^T [C_k P_k^- C_k^T + Q_v]^{-1}$; 状态估计观测更新方程为 $\hat{x}_k = \hat{x}_k^- + K_k(y_k - g(\hat{x}_k^-, i_k))$; 误差协方差观测更新方程为 $P_k = (I - K_k C_k) P_k^-$.

V_{\min} -EKF 方法在动力锂电池组 SOC 状态估计中的意义在于: 用安时积分法递推 SOC, 代入观测方程得到 V_{\min} 的估计值. 计算每 1 步的 Kalman 增益 K_k , 它反映了残差 $(y_k - g(x_k, i_k))$ 作用于状态变量 SOC 的权重, 由状态估计观测更新方程得到 SOC 的最优估计. V_{\min} -EKF 法克服了安时积分法累积电流误差的缺点, 实现了对状态变量 SOC 的闭环估计. 由于在计算过程中考虑了噪声的影响, 算法对噪声有很强的抑制作用^[1].

4 仿真实验及结果分析

为验证 V_{\min} -EKF 方法的优越性, 选取额定电压 240V, 额定容量 20A · h 的电动汽车电池组为实验对象. 该电池组共由 80 只单体 20A · h 的磷酸铁锂电池串联而成, 依据《电动道路车辆用锂离子蓄电池测试标准》^[11] 描述的电动汽车电池组模拟工况对电池组进行放电实验. 以实验数据为基础进行 Matlab 仿真, 并将 V_{\min} -EKF 法估计的 SOC 值与实际放电测得的真实 SOC 值进行比较.

将电池组充满电(SOC(0) = 100%), 在恒温条件下(20℃ ± 2℃) 按照电动汽车的模拟工况对电池组进行放电实验. 图 1 为实验过程中的放电电流波形. 整个放电过程时长 9350s, 采样间隔和 V_{\min} -EKF 递推过程时间间隔均为 10 s.




图 1 电池组模拟工况实验的放电电流波形

SOC 初始值根据电池的开路电压或上一次放电结束时存储的 SOC 值来确定, 由于电池的迟滞效应及自放电等因素, 初始值经常会存在较大的误差. 图 2 为 SOC(0) = 100% (无误差) 时 V_{\min} -EKF 方法估计的 SOC 值与实际放电测得的真实 SOC 值的对

比. 图 3 为 SOC(0) = 70% (30% 的初始误差) 时估计 SOC 值与真实 SOC 值的对比. 表 1 显示了放电截止时估计 SOC 值与真实 SOC 值的误差.

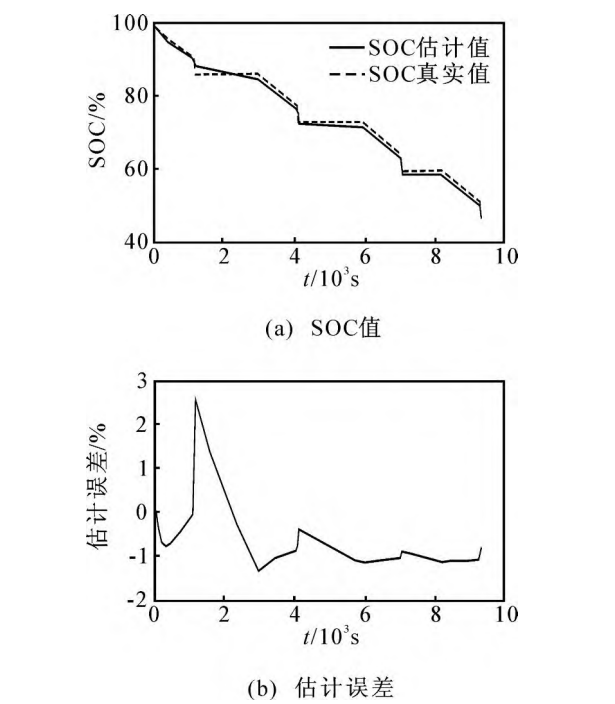


图 2 SOC 初始值无误差时的 V_{\min} -EKF 估计过程

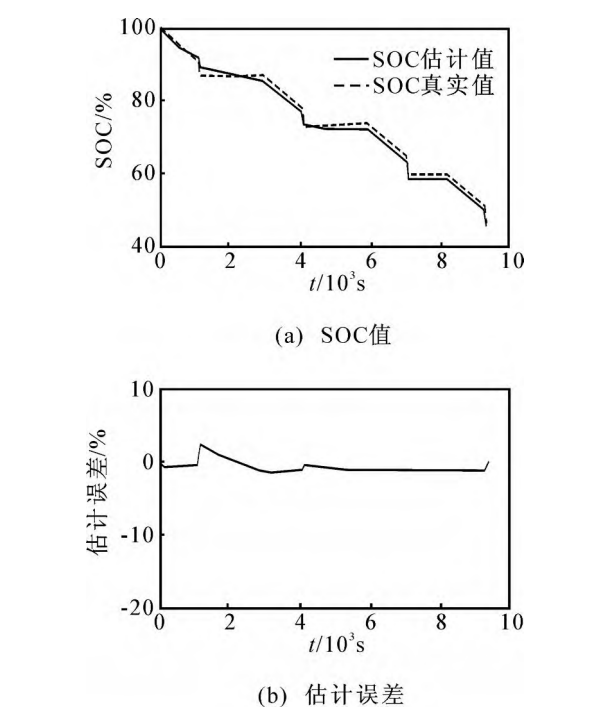


图 3 SOC 初始值有误差时的 V_{\min} -EKF 估计过程

表 1 不同初值时 V_{\min} -EKF 估计结果误差比较			
初始条件	V_{\min} -EKF	真实值	误差 /%
SOC(0) = 100% (无误差)	0.4592	0.4671	- 0.79
SOC(0) = 70% (30% 的误差)	0.4593	0.4671	- 0.78

当 SOC 初值无误差时, 整个 V_{\min} -EKF 估计过程误差都非常小, 最终误差为 - 0.79%. 当初始 SOC

值有 30% 的误差时, V_{\min} -EKF 估计过程仅用了 3 步递推就将估计误差缩小到 1% 以内. 放电截止时 SOC 估计误差为 -0.78%, 说明 V_{\min} -EKF 方法对于系统状态的初值误差有很好的修正作用.

电动汽车电流传感器大多采用霍尔元件, 精度有限, 造成电流测量值有较大的噪声甚至产生零点漂移. 在图 1 的电流值上加上均值为 0.5A, 方差为 0.25 的高斯白噪声, 利用 V_{\min} -EKF 方法、安时积分法分别对 SOC 值进行估计, 并与实际的 SOC 值进行对比, 如图 4 所示.

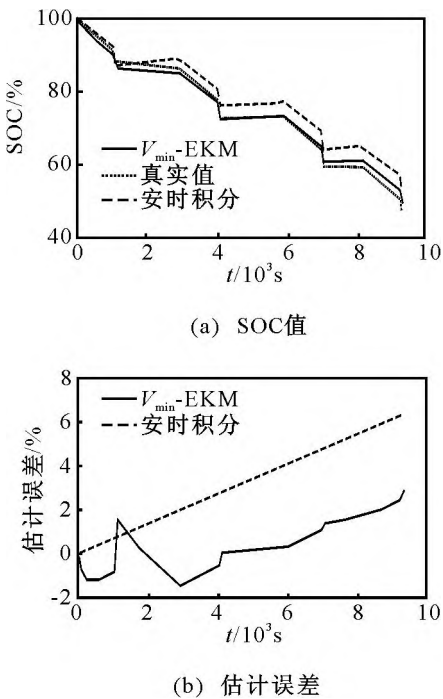


图 4 电流输入含噪声时的 SOC 估计

表 2 显示了放电截止时, V_{\min} -EKF 的估计误差为 2.72%, 安时积分法达到了 6.28%. 充分说明 V_{\min} -EKF 方法对输入噪声有很好的抑制作用.

表 2 V_{\min} -EKF 法与安时积分法估计结果误差比较

	估计值	真实值	误差 /%
V_{\min} -EKF 法	0.4943	0.4671	2.72
安时积分法	0.5299	0.4671	6.28

5 结 论

本文针对电动汽车动力锂电池组的 SOC 估计问题, 提出基于 V_{\min} 模型的 EKF 方法, 在单体电池的组态模型基础上, 建立串联电池组的非线性状态空间模型. 将电池组内单体电池负载电压的最小值 V_{\min} , 电池组的 SOC 分别作为模型的观测变量和状态变量, 通过一阶 Taylor 展开将电池组状态空间模型线性化, 并应用 Kalman 滤波法实现 SOC 的递归估计. 仿真结果表明, V_{\min} -EKF 方法在动力锂电池组 SOC 估计过程中有较高的精度, 能很好地修正

SOC 初始值的误差, 对噪声有较强的抑制作用. 动力锂电池组实际使用中, 容量 C_N 和内阻 R 会随温度、循环次数而变化, 进一步的研究可以采用 Dual EKF 方法或 Joint EKF 方法, 在电池组 SOC 估计的同时实现模型参数的在线辨识.

参考文献(References)

[1] 夏超英, 张术, 孙宏涛. 基于推广卡尔曼滤波算法的 SOC 估算策略[J]. 电源技术, 2007, 31(5): 414-417.
(Xia C Y, Zhang S, Sun H T. A strategy of estimating state of charge based on extened Kalman filter [J]. Chinese J of Power Sources, 2007, 31(5): 414-417.)

[2] 林成涛, 王军平, 陈全世. 电动汽车 SOC 估计方法原理与应用[J]. 电池, 2004, 34(5): 376-378.
(Lin C T, Wang J P, Chen Q S. Methods for state of charge estimation of EV batteries and their application [J]. Battery Bimonthly, 2004, 34(5): 376-378.)

[3] Zhu C B, Coleman M, Hurley W G. State of charge determination in a lead-acid battery: Combined EMF estimation and ah-balance approach[C]. IEEE Conf on Power Electronics Specialists. Aachen, 2004: 1908-1914.

[4] Caumont O, Le Moigne P, Rombaut C, et al. Energy gauge for lead-acid batteries in electric vehicles [J]. IEEE Trans on Energy Conversion, 2000, 15(3): 354-360.

[5] Shi P, Bu C G, Zhao Y W. The ANN models for SOC / BRC estimation of Li-ion battery [C]. IEEE Int Conf Acquisition. Hong Kong, 2005: 560-564.

[6] Li I H, Wang W Y, Su S F, et al. A merged fuzzy neural network and its applications in battery state-of-charge estimation [J]. IEEE Trans on Energy Conversion, 2007, 22(3): 697-708.

[7] Plett G L. Extended Kalman filtering for battery management systems of LiPB-based HEV battery packs [J]. J of Power Sources, 2004, 134(2): 277-292.

[8] Bhangu B S, Bentley P, Stone D A, et al. Nonlinear observers for predicting state-of-charge and state-of-health of lead-acid batteries for hybrid-electric vehicles [J]. IEEE Trans on Vehicular Technology, 2005, 54(3): 783-794.

[9] Lee S, Kim J, Lee J, et al. State-of-charge and capacity estimation of lithium-ion battery using a new open-circuit voltage versus state-of-charge [J]. J of Power Sources, 2008, 185(2): 1367-1373.

[10] Haykin S. Kalman filter and neural network [M]. New York: Wiley Inter-Science, 2001.

[11] QC/T743-2006, 电动道路车辆用锂离子蓄电池[S]. (QC/T743-2006, Lithium-ion Batteries for Electric Road Vehicles[S].)